

Buscas Online

Agentes que exploram ambientes desconhecidos

Prof. Marcelo de Souza

85ECS – Engenharia de Software Orientada a Agentes

Universidade do Estado de Santa Catarina

Busca offline vs. busca online



Planejamento e otimização

- ▶ Algoritmos clássicos de busca (offline);
- ▶ Ambiente: completo (observável), determinístico e estático;
- ▶ Percepção → solução completa → executa solução.
 - ▶ Não recorrem a novas percepções e não replanejam a solução!



Planejamento e otimização

- ▶ Algoritmos clássicos de busca (offline);
- ▶ Ambiente: completo (observável), determinístico e estático;
- ▶ Percepção → solução completa → executa solução.
 - ▶ Não recorrem a novas percepções e não replanejam a solução!

Busca online

- ▶ ação → observa o ambiente → calcula a próxima ação → ...
- ▶ Ideal para ambientes:
 - ▶ Dinâmicos (ou semi-dinâmicos, onde há um tempo para deliberação);
 - ▶ Não determinísticos;
 - ▶ **Desconhecidos**: quais os estados e o que fazem as ações?



Ideia geral

- ▶ Usar ações como experimentos para **explorar** e **aprender** sobre o ambiente;
- ▶ Computação “pura” não resolve.



Ideia geral

- ▶ Usar ações como experimentos para **explorar** e **aprender** sobre o ambiente;
- ▶ Computação “pura” não resolve.

O agente conhece:

- ▶ $ações(s)$: função que retorna a lista de ações permitidas no estado s ;
- ▶ $teste(s)$: função que testa se s é um estado objetivo.

O agente deve explorar (e aprender):

- ▶ S : o conjunto de estados do ambiente;
- ▶ $c(s, a)$: função de custo de executar a ação a no estado s ;
- ▶ $resultado(s, a)$: o efeito da ação a no estado s (i.e. estado seguinte s').



Busca offline

- ▶ exploração é feita antes de executar qualquer ação;
- ▶ permite explorar vários caminhos da árvore.

Busca online

- ▶ exploração: executar ações e observar os resultados;
- ▶ explorar um caminho diferente implica em “desfazer” uma série de ações (**custoso!**);
- ▶ exige estratégias de exploração específicas.

Busca offline


- ▶ exploração é feita antes de executar qualquer ação;
- ▶ permite explorar vários caminhos da árvore.

Busca online

- ▶ exploração: executar ações e observar os resultados;
- ▶ explorar um caminho diferente implica em “desfazer” uma série de ações (**custoso!**);
- ▶ exige estratégias de exploração específicas.

Imagine uma busca em largura na árvore ao lado.

- ▶ Busca em profundidade parece ideal para busca online!





Busca em profundidade online

Entrada : s' – percepção do estado atual

se $\text{teste}(s')$ **então retorna** solução

se $s' \notin \text{experimental}$ (i.e. novo estado) **então**

$\text{experimental}[s'] \leftarrow \text{ações}(s')$

se $s \neq \text{null}$ **então**

$\text{resultado}[s, a] \leftarrow s'$

 empilha s a retroceder[s']

se $\text{experimental}[s']$ é vazio **então**

se $\text{retroceder}[s']$ é vazio **então retorna** falha

$a \leftarrow \text{ação } b \text{ tal que } \text{resultado}[s', b] = \text{desempilha}(\text{retroceder}[s'])$

$s' \leftarrow \text{null}$

senão $a \leftarrow \text{desempilha}(\text{experimental}[s'])$

$s \leftarrow s'$


retorna a

- ▶ no início, o agente só conhece seu estado atual s' e suas ações;
- ▶ s e a são o estado e ação anteriores;
- ▶ experimental: ações a serem exploradas;
- ▶ resultado: conhecimento do agente;
- ▶ retroceder: estado de onde veio;
- ▶ agente explora e aprende enquanto busca o objetivo.

Busca em profundidade online

Exemplo (execução)

Execute a busca em profundidade online na árvore de estados abaixo.



VARIÁVEIS

$S' = A$
 $S = \text{NULL}$
 $Q = \text{NULL}$

RESULTADO

	A	B	C	D	E	F	G	H
1								
2								
3								
-1								
-2								
-3								

VOLTA


Experimentar

Retroceder

Busca em profundidade online

Exemplo (execução)

Execute a busca em profundidade online na árvore de estados abaixo (**estado final**).



VARIÁVEIS

$S' = F$

$S = B$

$q = 3$

RESULTADO

	A	B	C	D	E	F	G	H
1	B	D						
2		E						
3								
-1		A		B				
-2					B			
-3								

VOLTA

Experimentar

$A \rightarrow \cancel{X}, 2$

$B \rightarrow \cancel{X}, \cancel{X}, \cancel{X}$

$D \rightarrow \emptyset$

$E \rightarrow \emptyset$

Retroceder

$B \rightarrow A$

$D \rightarrow B$

$E \rightarrow B$



Quando o agente falha?

- ▶ Quando explora todos os estados e volta ao estado inicial.
- ▶ Neste caso, ele explorou todas suas ações e não tem pra onde retroceder.

Variantes:

- ▶ Busca em profundidade **limitada** online;
- ▶ Busca em **aprofundamento iterativo** online.



Por definição, buscas locais (*hill climbing*) expandem estados baseados na **localidade**.

- ▶ Ou seja, o algoritmo mantém o estado atual e explora as ações nesse estado;
- ▶ *Hill climbing* já é um algoritmo de **busca online**;
- ▶ **Problema:** o algoritmo simples fica preso em ótimos locais e *plateaus*.



Por definição, buscas locais (*hill climbing*) expandem estados baseados na **localidade**.

- ▶ Ou seja, o algoritmo mantém o estado atual e explora as ações nesse estado;
- ▶ *Hill climbing* já é um algoritmo de **busca online**;
- ▶ **Problema:** o algoritmo simples fica preso em ótimos locais e *plateaus*.

Que tal usar reinícios aleatórios?

- ▶ Não é possível, pois o agente não pode se transportar a outro estado;
- ▶ Mas, podemos fazer uma caminhada aleatória de n passos (executar ações aleatórias), o que leva o agente a um estado aleatório;
- ▶ **Problema:** o algoritmo é lento em cenários complexos.



Por definição, buscas locais (*hill climbing*) expandem estados baseados na **localidade**.

- ▶ Ou seja, o algoritmo mantém o estado atual e explora as ações nesse estado;
- ▶ *Hill climbing* já é um algoritmo de **busca online**;
- ▶ **Problema:** o algoritmo simples fica preso em ótimos locais e *plateaus*.

Que tal usar reinícios aleatórios?

- ▶ Não é possível, pois o agente não pode se transportar a outro estado;
- ▶ Mas, podemos fazer uma caminhada aleatória de n passos (executar ações aleatórias), o que leva o agente a um estado aleatório;
- ▶ **Problema:** o algoritmo é lento em cenários complexos.

Solução: usar buscas locais com **informação, memória e aprendizado!**

Learning real-time A* (LRTA*)

Entrada : s' – percepção do estado atual

se $\text{teste}(s')$ **então retorna** solução

se $s' \notin H$ (i.e. novo estado) **então**

$H[s'] \leftarrow h(s')$

se $s \neq \text{null}$ **então**

$\text{resultado}[s, a] \leftarrow s'$

$H[s] \leftarrow \min(\text{custo}(s, b), \forall b \in \text{ações}(s))$

$a \leftarrow \text{argmin}_b(\text{custo}(s', b), \forall b \in \text{ações}(s'))$

$s \leftarrow s'$

retorna a

function $\text{custo}(s, a)$:

se $\text{resultado}[s, a]$ é desconhecido **então retorna** $h(s)$


senão retorna $H[\text{resultado}[s, a]] + c(s, a)$

- ▶ no início, o agente só conhece seu estado atual s' e suas ações;
- ▶ s e a são o estado e ação anteriores;
- ▶ $h(s)$: função heurística para um estado s ;
- ▶ H : custo esperado de cada estado até o objetivo;
- ▶ resultado: conhecimento do agente;
- ▶ agente aprende a tomar decisões.

Busca local online

Exemplo (execução)

Execute a busca LRTA* no grafo de estados abaixo.



$S = A$
 $S = \text{NULL}$
 $a = \text{NULL}$

	A	B	C	D	E
1					
2					
3					


Resultados

H _____

Busca local online

Exemplo (execução)

Execute a busca LRTA* no grafo de estados abaixo (**estado final**).



$S = E$
 $S = D$
 $\alpha = 3$

	A	B	C	D	E
1	B	A	D		
2	C		A		
3					

Resultados

H	
A → 6	D → 1
C → 5	
B → 8	



Note que:

- ▶ A medida que o agente testa ações nos estados em que se encontra, ele aprende os efeitos de suas ações. Ou seja, ele toma conhecimento da transição de estados.
- ▶ Ele também atualiza a qualidade de cada estado para tomar decisões futuras.
- ▶ Esse conhecimento pode ser armazenado para execuções futuras, onde parte do ambiente já é conhecida.



Note que:

- ▶ A medida que o agente testa ações nos estados em que se encontra, ele aprende os efeitos de suas ações. Ou seja, ele toma conhecimento da transição de estados.
- ▶ Ele também atualiza a qualidade de cada estado para tomar decisões futuras.
- ▶ Esse conhecimento pode ser armazenado para execuções futuras, onde parte do ambiente já é conhecida.

Para avaliar a qualidade de um agente de busca online:

- ▶ Razão competitiva: caminho feito pelo agente vs. caminho ótimo;
- ▶ Número de estados avaliados vs. tamanho do espaço de estados.



Note que:

- ▶ A medida que o agente testa ações nos estados em que se encontra, ele aprende os efeitos de suas ações. Ou seja, ele toma conhecimento da transição de estados.
- ▶ Ele também atualiza a qualidade de cada estado para tomar decisões futuras.
- ▶ Esse conhecimento pode ser armazenado para execuções futuras, onde parte do ambiente já é conhecida.

Para avaliar a qualidade de um agente de busca online:

- ▶ Razão competitiva: caminho feito pelo agente vs. caminho ótimo;
- ▶ Número de estados avaliados vs. tamanho do espaço de estados.

Técnicas mais sofisticadas (exigem treinamento em ambiente simulado):

- ▶ Processos de decisão de Markov;
- ▶ Aprendizado por reforço.

85ECS – Engenharia de Software Orientada a Agentes
Prof. Marcelo de Souza